

N.L. Kozakova (<https://orcid.org/0000-0002-7780-7617>), M.H. Endeka
Oles Honchar Dnipro National University

SMART FINANCE MANAGEMENT SYSTEM BASED ON ARTIFICIAL INTELLIGENCE TECHNOLOGIES

This paper presents the development of an intelligent personal finance management system – “Smart Wallet”. The proposed system integrates modern artificial intelligence methods for automated analysis, anomaly detection, expense forecasting, budget optimization, and personalized recommendation generation. The architecture combines supervised and unsupervised learning algorithms, including k-Nearest Neighbors (k-NN) and decision trees for transaction classification, ARIMA and LSTM for financial forecasting, and Isolation Forests, autoencoders, and SVM for anomaly detection. Matrix factorization and collaborative filtering methods are used for generating recommendations. Furthermore, the system employs large language models (LLMs) to produce real-time textual advice based on aggregated financial activity. Data input includes categorized transaction history, timestamps, amounts, and merchant descriptions. The system is able to connect to external banking APIs for data retrieval and supports authentication via OAuth2. Thus, the “Smart Wallet” automates key financial operations and provides actionable recommendations tailored to individual user behavior. The integration of classical machine learning algorithms with generative AI creates a hybrid, extensible framework suitable for real-time financial support.

Key words: personal finance, smart assistant, anomaly detection, expense forecasting, artificial intelligence, machine learning, LLM, budget optimization.

Н.Л. Козакова (<https://orcid.org/0000-0002-7780-7617>), М.Г. Ендека
Дніпровський національний університет імені Олеся Гончара

ЗАСТОСУВАННЯ ШТУЧНОГО ІНТЕЛЕКТУ В УПРАВЛІННІ ОСОБИСТИМИ ФІНАНСАМИ

У роботі представлено інтелектуальну систему управління особистими фінансами – «Розумний гаманець», що поєднує сучасні методи штучного інтелекту для автоматизації фінансового аналізу, виявлення аномалій, прогнозування витрат і формування персоналізованих рекомендацій. Розроблена система орієнтована на користувачів, які прагнуть ефективно контролювати свої витрати, оптимізувати бюджет і приймати обґрунтовані фінансові рішення на основі аналітичних даних.

Архітектура «Розумного гаманця» включає кілька функціональних модулів: класифікацію транзакцій із використанням алгоритмів *k-найближчих сусідів (k-NN)* та *дерев рішень*; прогнозування витрат на основі моделей *ARIMA* та *LSTM*; виявлення підозрілих операцій за допомогою *автоенкодерів*, *Isolation Forest* та *SVM*; генерацію персоналізованих порад із застосуванням *великих мовних моделей (LLM)*. Рекомендаційний блок базується на методах колаборативної фільтрації та матричної факторизації, що забезпечує адаптацію системи до індивідуальних фінансових звичок користувача. Вхідними даними є транзакційна історія з інформацією про категорії, суми, часові мітки та описи операцій. Дані надходять із банківських API або

імпортуються з файлів CSV і зберігаються в базі *PostgreSQL*, що забезпечує масштабоване та надійне зберігання. Система генерує аналітичні візуалізації, виявляє аномалії, прогнозує фінансову активність і формує персоналізовані текстові рекомендації. Реалізація виконана мовою *Python* із використанням бібліотек *pandas*, *scikit-learn*, *tensorflow*, *statsmodels*, *surprise* та *openai*.

Отже, створена система забезпечує комплексну автоматизацію управління особистими фінансами, поєднуючи аналітичну точність, адаптивність і високий рівень персоналізації.

Ключові слова: штучний інтелект, особисті фінанси, прогнозування витрат, виявлення аномалій, рекомендаційна система, LLM, машинне навчання.

Introduction. The modern world is rapidly advancing toward digitalization and automation in all areas of life, and personal finance management is no exception. With the growing complexity of financial data, traditional budgeting methods are no longer sufficient for achieving the desired level of accuracy and adaptability. Artificial Intelligence (AI) technologies have demonstrated great potential in transforming how individuals interact with financial systems. One of the promising directions is the creation of the “Smart Wallet” – an intelligent system designed to automate financial record-keeping, analysis, and optimization of user financial activity.

This study focuses on the key aspects of such a system, including automated transaction categorization, expense forecasting, budget optimization, anomaly detection, and personalized recommendation generation. Special attention is given to the use of machine learning algorithms in financial data analysis and prediction.

Analysis of research and publications. Over the past five years, research aimed at automating financial monitoring and forecasting costs using machine learning and deep learning algorithms has intensified. In particular, Mienye (2024) and Li, Ding, and Chen (2023) discuss the application of deep learning models and large language models (LLMs) in financial analytics.

LSTM and GRU algorithms continue to demonstrate high efficiency in forecasting financial time series (Kong et al., 2025), but recent studies emphasize the advantages of Transformer architectures for long-term forecasting (Su et al., 2024). In parallel, hybrid models are being developed that combine statistical methods (ARIMA) with neural networks (Li et al., 2025).

Density-based clustering methods, such as HDBSCAN, are successfully used to segment customers and detect anomalies in transaction data (Afzal et al., 2024). In addition, research on NLP approaches demonstrates the effectiveness of vectorizing text descriptions of transactions for their automatic categorization (ResearchGate, 2023).

Thus, current trends are aimed at integrating various approaches – from statistical and neural to generative – to create adaptive financial systems capable of self-learning and personalization.

System Architecture. The Smart Wallet system has a two-level modular architecture consisting of two main functional blocks:

Block A – Analytical and Computational Unit Responsible for data preparation, classification, anomaly detection, and forecasting of financial information.

Block B – Artificial Intelligence and Recommendation Unit utilizes the results of Block A to generate personalized recommendations using large language models (LLMs).

The modular structure allows scalability, simple integration with external banking APIs, and flexibility in data processing. All data are stored in a PostgreSQL database, while inter-module communication is handled via REST API.

Applied Methods. The k-NN algorithm is used for automatic categorization of transactions based on similarity to historical samples. The similarity is computed using the Euclidean distance:

$$d(x_i, x_j) = \sqrt{\sum_{k=1}^m (x_{i,k} - x_{j,k})^2},$$

where

- x_i and x_j – two objects (feature vectors) between which the distance is measured;
- m – the number of features in each object;
- $x_{i,k}$ – the value of the k -th feature in vector x_i ;
- $d(x_i, x_j)$ – the Euclidean distance between objects x_i and x_j .

Decision trees. The information gain criterion is the main method used in decision tree algorithms (in particular, ID3, C4.5, C5.0) to select the best attribute at each step of tree construction. At each stage, the decision tree selects the feature whose division provides the greatest information gain, i.e., the one that most reduces entropy (uncertainty) in the sample. Information gain is defined as the difference between the entropy of the initial sample and the weighted average entropy of the subsets after division by attribute A :

$$IG(S, A) = H(S) - \sum_{v \in \text{values}(A)} \frac{|S_v|}{|S|} H(S_v),$$

where

$IG(S, A)$ – information gain obtained by using attribute A ;

$H(S)$ – the entropy of the current dataset S ;

$\text{Values}(A)$ – all possible values of attribute A ;

S_v – the subset of S , where attribute A has value v ;

$|S_v|/|S|$ – the proportion of samples that fall into subset S_v ;

$H(S_v)$ – the entropy of subset S_v .

ARIMA (Auto Regressive Integrated Moving Average).

ARIMA models are used for expense forecasting based on previous data:

$$(1 - \sum_{i=1}^p \phi_i L^i)(1 - L)^d y_t = (1 + \sum_{i=1}^q \theta_i L^i) \epsilon_t.$$

where

L – lag operator, such that $Ly_t = y_{t-1}$, $L^2 y_t = y_{t-2}$;

d – the number of differences required to make the series stationary;

$(1 - L)^d$ – differentiation operator, i.e.:

– at $d = 1$: $y'_t = y_t - y_{t-1}$;

– at $d = 2$: $y''_t = (y_t - y_{t-1}) - (y_{t-1} - y_{t-2})$;

ϕ_i – coefficients *AR*- parts;

θ_i – coefficients *MA*- parts;

ϵ_t – random error at the moment t .

LSTM (Long Short-Term Memory)

LSTM neural networks capture long-term dependencies in financial sequences. Their internal mechanisms are defined by the following equations:

Forget Gate:

$$z_t = \sigma(W_z \cdot [h_{t-1}, x_t]),$$

Input Gate:

$$r_t = \sigma(W_r \cdot [h_{t-1}, x_t]),$$

$$\tilde{h}_t = \tanh(W \cdot [r_t * h_{t-1}, x_t]),$$

Output Gate:

$$h_t = (1 - z_t) * h_{t-1} + z_t * \tilde{h}_t.$$

where

z_t – renewable gate output (value between 0 i 1);

σ – sigmoid activation function, which compresses values across the range [0,1];

W – weight matrix;

h_{t-1} – hidden state in the previous step;

x_t – output data at the current step;

r_t – output reset gate (value between 0 i 1);

$\tilde{h}_t$ – candidate for a new hidden state;

h_t – new hidden state at the current step.

Autoencoders.

Autoencoders detect anomalies by measuring reconstruction error:

$$L(x, \hat{x}) = \frac{1}{n} \sum_{i=1}^n (x_i - \hat{x}_i)^2,$$

where

$x = (x_1, x_2, \dots, x_n)$ – input data vector;

$\hat{x} = (\hat{x}_1, \hat{x}_2, \dots, \hat{x}_n)$ – reconstructed data vector after passing through the autoencoder;

n – number of features (dimensionality of the input vector);

$L(x, \hat{x})$ – reconstruction loss value;

$(x_i - \hat{x}_i)^2$ – squared difference between actual and reconstructed features.

Support Vector Machines (SVM).

SVM identifies the boundary between normal and anomalous transactions:

$$f(x) = \text{sign}\left(\sum_{i=1}^n \alpha_i K(x, x_i) - p\right),$$

where

x – the new input object being tested;

x_i – support vectors from the training dataset;

n – number of support vectors;

α_i – Lagrange multipliers (weights), most of which are zero;

$K(x, x_i)$ – kernel function measuring similarity between x and x_i ;

p – bias term (threshold);

$\text{sign}()$ – decision function returning:

+1, if the result is $> 0 \rightarrow$ normal point;

-1, if the result is $< 0 \rightarrow$ anomaly.

A distinctive feature of Smart Wallet is the use of large language models (LLM) to generate text recommendations. After calculations, the system transmits

the summarized data to the LLM, which forms conclusions in a format that is understandable to the user, for example:

"Your transportation expenses have increased by 15% this month. We recommend switching to a monthly pass to reduce your expenses."

Thus, the system not only analyzes data but also provides intelligent communication with the user.

Experimental Results. Testing on a dataset of 1000 transactions (Fig. 1) demonstrated the following results:

- Classification accuracy: 91.2% (k-NN + Decision Trees).
- Mean Absolute Percentage Error (MAPE): 6.8% (ARIMA), 5.4% (LSTM).
- F1-score for anomaly detection: 0.86 (Autoencoders + Isolation Forest).
- Recommendation precision: 0.89.

The experimental results demonstrate that combining traditional statistical models with modern AI techniques enhances the performance of personal finance management systems.

After passing through Block A, the dataset is normalized, cleaned of redundant information, and structured for further analysis (Fig. 2).

At this stage, the data has been normalized, categorized for more efficient analysis, and cleared of irrelevant elements.

```
22.04.2024,інвестиц.,9116,витрата,онлайн підписка
09.02.2024,інвестиц.,14203,витрата,рахунок
20.01.2024,фріланс,13943,дохід,покупка в магазині
10.04.2024,Їжа-дост.,4843,витрата,покупка в магазині
19.01.2024,підписки,13786,дохід,
22.01.2024,зарплата,7488,,картка
21.04.2024,Транспорт,6865,,переказ з карти
01.03.2024,підписки,6732,,покупка в магазині
26.02.2024,Зарплата,12710,витрата,рахунок
04.04.2024,Житло,???,дохід,
24.03.2024,Фріланс,6031,,рахунок
27.04.2024,Їжа доставка,6420,витрата,рахунок
26.04.2024,Продукти,7434,,переказ з карти
22.01.2024,Оренда,7849,,рахунок
28.03.2024,розв,2212,,
13.03.2024,Розваги,13847,,онлайн підписка
04.02.2024,підписки,4619,дохід,картка
29.01.2024,ПРОДУКТИ,12076,витрата,оплата послуг
14.04.2024,Інвест,1705,дохід,
20.03.2024,Продукти,10683,витрата,переказ з карти
```

Fig. 1. Example of the raw DataFrame containing users' transactional data prior to pre-processing

ID	Дата	Категорія	Опис	Сума	Тип	Оцінка
1	2024-04-16	Одяг	Одяг транзакція №1	18015	ВИТРАТА	Норм
2	2024-04-06	Навчання	Навчання транзакція №2	8351	ВИТРАТА	Низько
3	2024-02-01	Доставка їжі	Доставка їжі транзакція №3	18616	ВИТРАТА	Високо
4	2024-04-10	Подарунки	Подарунки транзакція №4	10660	ДОХІД	Низько
5	2024-03-20	Фриланс	Фриланс транзакція №5	6640	ДОХІД	Рекомендовано
6	2024-03-22	Продукти	Продукти транзакція №6	18788	ВИТРАТА	Рекомендовано
7	2024-03-01	Розваги	Розваги транзакція №7	10148	ВИТРАТА	Підозріло
8	2024-01-19	Комунальні послуги	Комунальні послуги транзакція №8	3756	ВИТРАТА	Підозріло
9	2024-04-18	Транспорт	Транспорт транзакція №9	13199	ВИТРАТА	Низько
10	2024-02-28	Медицина	Медицина транзакція №10	16860	ВИТРАТА	Рекомендовано
11	2024-02-20	Медицина	Медицина транзакція №11	14740	ВИТРАТА	Низько
12	2024-03-20	Навчання	Навчання транзакція №12	5135	ВИТРАТА	Підозріло
13	2024-02-09	Доставка їжі	Доставка їжі транзакція №13	2940	ВИТРАТА	Високо
14	2024-01-09	Доставка їжі	Доставка їжі транзакція №14	6228	ВИТРАТА	Норм
15	2024-01-08	Побутова хімія	Побутова хімія транзакція №15	13217	ВИТРАТА	Норм
16	2024-01-30	Інвестиції	Інвестиції транзакція №16	9030	ДОХІД	Підозріло
17	2024-04-14	Домашні тварини	Домашні тварини транзакція №17	3114	ВИТРАТА	Норм
18	2024-02-17	Навчання	Навчання транзакція №18	6071	ВИТРАТА	Низько
19	2024-03-01	Навчання	Навчання транзакція №19	14054	ВИТРАТА	Низько
20	2024-03-29	Доставка їжі	Доставка їжі транзакція №20	6449	ВИТРАТА	Низько
21	2024-03-11	Навчання	Навчання транзакція №21	18445	ВИТРАТА	Рекомендовано
22	2024-02-21	Подарунки	Подарунки транзакція №22	48993	ДОХІД	Підозріло
23	2024-04-21	Навчання	Навчання транзакція №23	10708	ВИТРАТА	Підозріло
24	2024-01-03	Доставка їжі	Доставка їжі транзакція №24	19887	ВИТРАТА	Підозріло
25	2024-03-22	Навчання	Навчання транзакція №25	10067	ВИТРАТА	Рекомендовано
26	2024-01-13	Зарплата	Зарплата транзакція №26	4664	ДОХІД	Рекомендовано

Fig. 2. Processed DataFrame ready for model training

The processed DataFrame is then transferred to **Block B**, where it is analyzed by a locally deployed and configured AI module that generates insights and recommendations (Fig.3).

```

💡 Фінансова порада:
1. **Переглянь витрати на доставку їжі:** Розглянь можливість готувати більше вдома, це може значно зменшити витрати на доставку їжі і зберегти гроші.
2. **Бюджетуй витрати на розваги:** Спробуй обмежити суму, яку витрачаєш на розваги. Подумай про альтернативні, більш економічні способи проведення часу.
3. **Оптимізуй витрати на оренду житла:** Якщо можливо, розглянь варіанти менш дорогого житла або пошуку співмешканця для поділу витрат.
4. **Збільши суму, яку відкладаєш:** Розглянь можливість збільшити суму, яку відкладаєш на заощадження, щоб мати більше фінансової стабільності в майбутньому.
5. **Постановка мети для інвестицій:** Розглянь планування цілей для своїх інвестицій, щоб забезпечити більш ефективне управління фінансами.

Пам'ятай, що важливо бути уважним при витрачанні грошей і завжди планувати свої фінанси на майбутнє.

```

Fig. 3. AI-generated feedback and recommendations

The system consists of seven main modules responsible for data preprocessing, transaction analysis, anomaly detection, forecasting, and AI-driven recommendations. The integrated workflow provides users with actionable insights to enhance their financial management.

The key modules of the system are as follows:

data_loader.py – responsible for preparing and loading raw financial data;

classification.py – identifies potentially fraudulent transactions;

anomaly_detection.py – detection of transactions that significantly deviate from normal user behavior;

forecasting.py – predicts future expenses, taking into account upcoming events and holidays;

recommender.py – generates personalized recommendations based on user preferences and spending patterns;

ai_answer.py – produces contextual responses and insights from the AI model;

index.py – serves as the main script that integrates and executes all system modules.

As a result, the user receives clear, data-driven recommendations aimed at improving their financial well-being.

Conclusions. The developed prototype of an intelligent personal finance management system has demonstrated high efficiency in performing the tasks set. The main advantages of the system are high accuracy of expense classification, the ability to predict future financial events based on historical trends, and reliable detection of anomalies that may indicate technical errors or potential fraud.

An additional advantage is the implementation of a personalized recommendation module that generates advice based on an analysis of the user's individual financial behavior. This ensures the practical usefulness of the system and creates the conditions for its further integration into financial applications and decision support services. In the future, further research plans include expanding the system's functionality through deeper integration with banking APIs and the use of hybrid machine learning models.

Bibliographic references

1. Mienye E. *Deep learning in finance: A survey of applications and techniques*. MDPI. 2024. P. 2066-2091. <https://www.mdpi.com/2673-2688/5/4/101>
2. Li Y., Ding H., & Chen H. *Large language models in finance: A survey*. arXiv. 2023. <https://arxiv.org/abs/2311.10723>. arxiv.org
3. Kong X., et al. *Deep learning for time series forecasting: A survey*. Springer. 2025. P. 5079–5112. <https://doi.org/10.1007/s13042-025-02560-w>. link.springer.com
4. Su L., et al. *A systematic review for transformer-based long-term series forecasting*. *Artificial Intelligence Review*. 2024. 33 p. <https://doi.org/10.1007/s10462-024-11044-2>. link.springer.com
5. Li J. C., et al. *Enhancing financial time series forecasting with hybrid deep-learning models*. *Information Sciences (Elsevier)*. 2025. 19 p. [tandfonline.com](https://www.tandfonline.com)
6. Afzal, M., et al. *Segmentation and churn analysis using HDBSCAN and alternatives*. *DiVA Portal*. 2024. <https://www.diva-portal.org>
7. *Machine learning for financial transaction classification using character-level embeddings*. *ResearchGate*. 2023. P. 159–172. <https://www.researchgate.net>

Received 02.09.2025.